МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ

Национальный исследовательский ядерный университет «МИФИ»



Институт интеллектуальных кибернетических систем.

Кафедра кибернетики (№22)

Направление подготовки 09.03.04 Программная инженерия

Отчёт о работе по курсу «Базы данных (теоретические основы баз данных)»

Вариант: онлайн журнал(habr)

Выполнил: Радецкий Алексей

Группа: Б22-554

Преподаватель: Петровская А.В.

Оглавление

1. Формулировка задания	3
. , ,	
2.1. Конкретизация предметной области	
2.2. Описание предметной области	
2.3. Описание атрибутов	
3. Логическое проектирование	
4. Физическое проектирование	
4.2. Заполнение базы данных	
4.3. Результаты заполнения	10
5. Выполнение запросов	13

1. Формулировка задания

Спроектировать базу данных для работы онлайн журнала с научно-популярными и обучающими статьями о технологиях (как Habr). База данных должна содержать информацию о пользователях, авторах, статьях, разделах сайта, отражать связи между статьями, авторами и пользователями. Хранить информацию о просмотрах, комментариях, рейтингах.

2. Концептуальная модель базы данных

После проведения анализа предметной области была спроектирована следующая концептуальная модель:

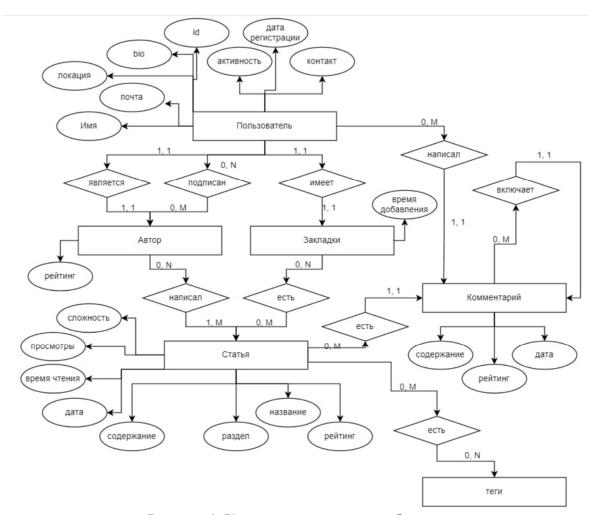


Рисунок 1. Концептуальная модель базы данных

2.1. Конкретизация предметной области

Необходимо создать систему, отражающую информацию о пользователях, авторах, статьях, разделах сайта, отражать связи между статьями, авторами и пользователями. Хранить информацию о просмотрах, комментариях, рейтингах.

2.2. Описание предметной области

Система рассчитана на работу с зарегистрированными пользователями, как с авторами, так и с читателями статей. Пользователь может являться автором. Пользователи могут читать статьи, что отражается на просмотрах, комментировать статьи, добавлять их

в закладки (поставить лайк), оценивать статьи, что должно отражаться на их рейтинге, оценивать авторов. Авторы могут создавать статьи и относить их к разделам сайта. Комментарии можно писать не только на статьи, но и на другие комментарии (дерево комментариев).

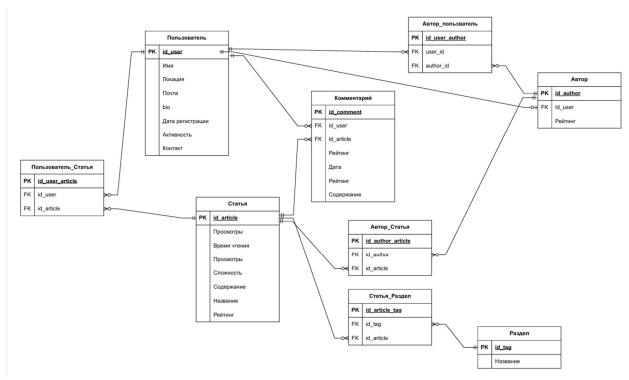
2.3. Описание атрибутов

В процессе анализа были выделены следующие атрибуты, название и описание которых приведены в таблице ниже:

Имя атрибута	Расшифровка
id	Уникальный идентификатор. Есть у
	каждого объекта.
Дата регистрации	Дата регистрации пользователя
Активность	Дата и время последней активности
	пользователя
Контакт	Контактные данные оставленные
	пользователем для других пользователей
bio	Информация о пользователе, которую он
	оставил для других пользователей
Локация	Страна пользователя
Почта	Почта пользователя
Имя	Никнейм пользователя
Рейтинг	Оценка в диапазоне
	[-100;100] сформированная, на основе
	мнения других пользователей
Дата	Время создания статьи или комментария
Тег	Раздел сайта (тема) к которому относится
	статья
Время чтения	Время необходимое для прочтения статьи
Просмотры	Количество просмотров

3. Логическое проектирование

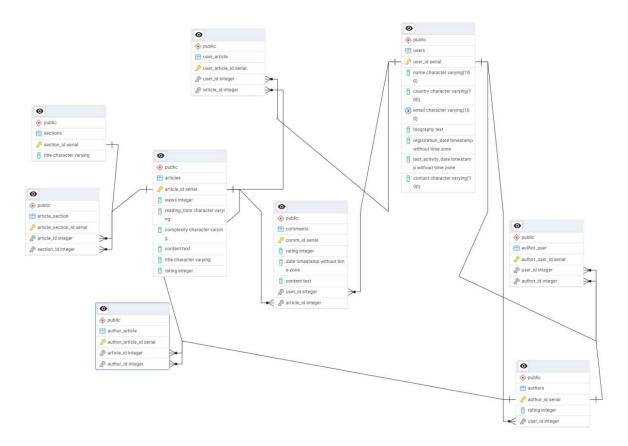
Следующим шагом на основе КМПО была разработана логическая модель базы данных, представленная ниже:



Есть 4 промежуточных таблицы: пользователь_статья, автор_статья, статья_раздел, автор_пользователь. С их помощью реализованы отношения многие ко многим. Все таблицы находятся в нормальной форме.

4. Физическое проектирование

В качестве СУБД для реализации разработанной базы данных была выбрана PostgreSQL. В связи с проведённым анализом предметной области была проработана следующая физическая схема БД. Она представлена на следующем рисунке



4.1. Создание таблиц

Ниже приведен код на python (использовалась orm sqlalchemy) для создания таблиц, описанных выше.

User:

```
Base = declarative_base()

class User(Base): 3 usages

__tablename__ = 'users'

user_id = Column(Integer, primary_key=True, autoincrement=True)

name = Column(String, nullable=False)

country = Column(String, nullable=False)

email = Column(String, nullable=False, unique=True)

biography = Column(Text, nullable=True)

registration_date = Column(DateTime, server_default=func.now())

last_activity_date = Column(DateTime, onupdate=func.now())

contact = Column(String, nullable=True)
```

Comment

```
class Comment(Base): 3 usages

__tablename__ = 'comments'

comm_id = Column(Integer, primary_key=True, autoincrement=True)

rating = Column(Integer, nullable=False)

parent_id = Column(Integer, nullable=True)

date = Column(DateTime, server_default=func.now())

content = Column(Text, nullable=False)

user_id = Column(Integer, ForeignKey('users.user_id'))

article_id = Column(Integer, ForeignKey('articles.article_id'))

article_id = Column(Integer, ForeignKey('articles.article_id'))
```

Article

```
class Article(Base): 2 usages

__tablename__ = 'articles'

article_id = Column(Integer, primary_key=True, autoincrement=True)

views = Column(Integer, default=0)

date = Column(DateTime, server_default=func.now())

reading_time = Column(String, nullable=False)

complexity = Column(String, nullable=False)

content = Column(Text, nullable=False)

title = Column(String, nullable=False)

rating = Column(Integer, nullable=True)
```

User article

```
class UserArticle(Base): 2 usages

__tablename__ = 'user_article'

user_article_id = Column(Integer, primary_key=True, autoincrement=True)

user_id = Column(Integer, ForeignKey('users.user_id'))

article_id = Column(Integer, ForeignKey('articles.article_id'))

52
```

Author user

```
class AuthorUser(Base):
__tablename__ = 'author_user'

author_user_id = Column(Integer, primary_key=True, autoincrement=True)

user_id = Column(Integer, ForeignKey('users.user_id'))

author_id = Column(Integer, ForeignKey('authors.author_id'))
```

Author

```
class Author(Base): 3 usages

__tablename__ = 'authors'

author_id = Column(Integer, primary_key=True, autoincrement=True)

rating = Column(Integer, nullable=True)

user_id = Column(Integer, ForeignKey('users.user_id'))
```

Author article

```
class AuthorArticle(Base): 3 usages

__tablename__ = 'author_article'

author_article_id = Column(Integer, primary_key=True, autoincrement=True)

article_id = Column(Integer, ForeignKey('articles.article_id'))

author_id = Column(Integer, ForeignKey('authors.author_id'))
```

Section

```
class Section(Base): 3 usages

__tablename__ = 'sections'

section_id = Column(Integer, primary_key=True, autoincrement=True)

title = Column(String, nullable=False)
```

Article section

```
class ArticleSection(Base): 2 usages

__tablename__ = 'article_section'

article_section_id = Column(Integer, primary_key=True, autoincrement=True)

article_id = Column(Integer, ForeignKey('articles.article_id'))

section_id = Column(Integer, ForeignKey('sections.section_id'))
```

Создание таблиц

4.2. Заполнение базы данных

Заполнение базы данных проводилось при помощи Python, sqlalchemy, faker. Были подготовлены csv файлы со сгенерированными комментариями и тегами статей. Остальные данные генерировались с помощью библиотеки faker.

Порядок вызова функций для заполнения таблиц:

```
if __name__ == "__main__":
    engine = create_engine("postgresql://postgres:923709@localhost/mephi_db_habr_v1", echo=True)
    Session = sessionmaker(bind=engine)
    session = Session()
    fake = Faker()

    unit_users(session, fake)
    unit_authors(session, fake)
    article_count = unit_articles(session, fake)
    unit_sections(session, fake, article_count)
    unit_comments(session, fake, article_count)
    session.close()
```

Таблица users

```
def unit_users(session: Session, fake: Faker) -> list[User]: 2 usages
    users = []
    for i in range(c.USER_NUM):
        name = fake.unique.user_name()
        country = fake.country()
        email = fake.unique.email(),
        biographic = fake.text(max_nb_chars=200)
        registration_date = fake.date()
        last_activity_date = fake.date_between(start_date=date.fromisoformat(registration_date))
        contact = fake.basic_phone_number()
        users.append(User(name=name, country=country, email=email, biography=biographic, registration_date=regilast_activity_date=last_activity_date, contact=contact))
    session.add_all(users)
    session.commit()
    return users
```

Таблина authors

```
def unit_authors(session: Session, fake: Faker) -> list[Author]: 2 usages
a = [i for i in range(1, c.USER_NUM + 1)]
user_id_sample = random.sample(a, c.AUTHOR_NUM)
authors = []
for i in range(c.AUTHOR_NUM):
    rating = random.randint(-1 * c.RATING_MAX_ABS, c.RATING_MAX_ABS)
    user_id = user_id_sample[i]
    authors.append(Author(rating=rating, user_id=user_id))
session.add_all(authors)
session.commit()
return authors
```

Таблицы article, author article, user article

```
def unit_articles(session: Session, fake: Faker) -> int: 2 usage
   articles = []
   author_article = []
   for i in range(c.AUTHOR_NUM):
          reading_time = random.choice(['30 min', '12 min', '1 hour', 'less then 5 min', '10 min', '2 hour'])
          date_article = fake.date()
         rating = random.randint(-1 * c.RATING_MAX_ABS, c.RATING_MAX_ABS)
         author_article.append(AuthorArticle(article_id=article_id, author_id=(i + 1)))
             author_article.append(AuthorArticle(article_id=article_id, author_id=random.randint( a: 1,c.AUTHOR_NUM)))
         article_id += 1
   article_id -= 1
   user_article = []
   user_arr = [i for i in range(1, c.USER_NUM + 1)]
   article_sample = random.sample(article_arr, article_id - 1000)
   for i in range(len(article_sample)):
       for j in range(len(user_sample)):
          user_article.append(UserArticle(user_id=user_sample[j], article_id=article_sample[i]))
   session.add_all(articles)
   session.add_all(author_article)
   session.add_all(user_article)
```

Таблица sections

```
def unit_sections(session: Session, fake: Faker, article_count: int) -> list[Section]: 2 usages
   sections = []
   section_article = []
   sections_from_file = []
   article_arr = [i for i in range(1, article_count + 1)]
          sections_from_file.append(row[0])
section_count = len(sections_from_file)
   for i in range(section_count):
       sections.append(Section(title=sections_from_file[i]))
       article_sample = random.sample(article_arr, random.randint( a: 20, b: 1000))
      for j in range(len(article_sample)):
           section_article.append(ArticleSection(article_id=article_sample[j], section_id=i + 1))
   session.add_all(sections)
   session.commit()
   session.add_all(section_article)
   session.commit()
```

Таблица comments

4.3. Результаты заполнения

Далее представлены результаты работы программы на примере таблиц, соответствующих функциям, приведенным выше.

Authors

	author_id [PK] integer	rating integer	user_id integer
1	1	60	4237
2	2	-79	4996
3	3	-58	1552
4	4	64	6030
5	5	-62	7349
6	6	45	7634
7	7	29	6534
8	8	-97	9615
9	9	18	2738
10	10	-4	2899
11	11	17	3498

Users

	user_id [PK] intege	name character varying	country character varying	email character varying	biograph text	registration_data timestamp with		contact character varying
1	1	villegaschase	El Salvador	jordan56@example.org	Exac	1993-07-11	2010-06-28	383-965-6405
2	2	mollymccall	Tokelau	rhoward@example.com	Crim	1990-04-02	2021-02-05	(898)604-8474
3	3	lee98	Austria	wmata@example.com	Mor	2011-04-24	2019-04-09	5494613747
4	4	ashley41	Suriname	vbaker@example.net	Both	1982-03-02	1995-10-15	(209)407-9970
5	5	nevans	Turkmenistan	petersonmadison@exam	Offi	1976-12-30	1981-11-14	4425884193
5	6	greenedebor	Cuba	adamsnicole@example.c	Atte	1986-04-22	1988-07-12	(401)934-5804
7	7	kthornton	Nauru	nsims@example.com	Littl	1973-01-11	1987-04-02	(520)858-9830
В	8	xstout	Armenia	spencermatthew@exam	L00	2024-11-21	2024-11-25	(344)338-8871
9	9	nicholasclay	Norfolk Island	nlester@example.org	May	2011-02-18	2017-10-25	668-641-5777
10	10	xwallace	Uganda	hunter76@example.net	Inter	1972-09-11	1996-09-15	379-829-8457
11	11	knoxdeborah	Chad	renee86@example.org	Parti	2010-01-03	2012-05-29	(250)800-3591

Articles

	article_id [PK] integ		date timestamp with	reading_tir character			title character varying	rating integer
1	1	55499	1988-12-31	10 min	hard	Let's imagine that it's the text of an articleEffo	It's titleItem worker blood raise.	69
2	2	61268	1978-07-16	2 hour	easy	Let's imagine that it's the text of an articleKey \dots	It's titleNor car commercial as.	-4
3	3	42516	2014-03-11	1 hour	easy	Let's imagine that it's the text of an article Even	It's titleMan bar all election.	-40
4	4	72708	2009-10-01	10 min	easy	Let's imagine that it's the text of an article Trav	It's titleColor movie when page.	-36
5	5	78255	1976-07-18	1 hour	medi	Let's imagine that it's the text of an articleSinc	It's titleBelieve pass tax body.	-84
6	6	29898	1970-01-02	12 min	hard	Let's imagine that it's the text of an articleLet \dots	It's titleOften heavy lead with.	14
7	7	70066	2004-03-09	30 min	easy	Let's imagine that it's the text of an articleSch	It's titlePm economy do rich.	56
8	8	93023	1974-08-02	10 min	easy	Let's imagine that it's the text of an articleEast	It's titleItself give part answer.	-44
9	9	75254	1992-03-13	12 min	hard	Let's imagine that it's the text of an articleHan	It's titleMe right can man.	19
10	10	74970	2011-01-01	30 min	easy	Let's imagine that it's the text of an article Vote	It's titleYard push water brother.	-32
11	11	97033	1971-04-13	30 min	hard	Let's imagine that it's the text of an articleSec	It's titleImpact hope specific.	-43
12	12	5309	1977-11-28	less th	hard	Let's imagine that it's the text of an articleSite	It's titleCareer thus now.	87

Comments

	comm_id [PK] integer	rating integer	parent_id integer	date timestamp without time	content text	user_id integer	article_id integer
1	1	-50	[null]	2006-03-04 00:00:00	Спасибо за статью! Очень интер	5767	1
2	2	-69	[null]	1980-02-25 00:00:00	А как насчет безопасности? Этот	9185	1
3	3	81	[null]	1970-05-03 00:00:00	Спасибо за информацию, очень	6584	1
4	4	-33	[null]	1978-07-23 00:00:00	Спасибо за подробный обзор! Оч	763	1
5	5	-91	[null]	1992-04-15 00:00:00	Спасибо за статью, очень захват	9018	1
6	6	47	[null]	1986-03-05 00:00:00	А как насчет поддержки старых	1453	1
7	7	93	[null]	1994-04-21 00:00:00	Если бы я знал, что здесь публик	9038	1
8	8	-68	[null]	1982-06-21 00:00:00	Не могу поверить, что этот матер	9578	1
9	9	43	[null]	2008-08-11 00:00:00	Спасибо за подробный анализ! О	9562	1
10	10	-100	[null]	1978-06-27 00:00:00	Я бы посоветовал использовать	797	1
11	11	9	[null]	2002-07-09 00:00:00	Статья очень познавательна, мн	7509	1
12	12	-6	[null]	1976-10-02 00:00:00	Статья очень понравилась, мног	79	1
13	13	55	[null]	1995-12-07 00:00:00	Я бы посоветовал использовать	5716	1
1.4	1.4	22	[11]	1000 06 16 00:00:00	0 500	E177	1

Sections

	section_id [PK] integer	title character varying
1	1	python
2	2	комбинаторика
3	3	алгоритмы сортировки
4	4	машинное обучение
5	5	нейронные сети
6	6	искусственный интеллект
7	7	большие данные
8	8	облачные вычисления
9	9	кибербезопасность
10	10	блокчейн

Article section

	article_section_id [PK] integer	article_id integer	section_id integer
1	1	7893	1
2	2	22287	1
3	3	6240	1
4	4	7976	1
5	5	5042	1
6	6	12618	1

Author_article

	author_article_id [PK] integer	article_id integer	author_id integer
1	1	1	1
2	2	2	2
3	3	3	2
4	4	4	2
5	5	5	2
6	6	5	1260
7	7	6	2
8	8	7	2
9	9	8	3

User article

	user_article_id .	user_id .	article_id .
	[PK] integer	integer	integer /
1	1	9459	20756
2	2	3208	20756
3	3	9334	20756
4	4	9607	20756
5	5	4653	20756
6	6	4692	20756
7	7	2580	20756
8	8	3421	20756
9	9	8575	20756
10	10	8050	20756

5. Выполнение запросов

В этом разделе приведены различные запросы к реализованной базе данных — их краткие описания, непосредственно запрос на языке SQL и результат выполнения.

1.1 Для каждого автора найти количество просмотров его статей

```
2 SELECT sum(a.views) AS all_views, aa.author_id, u.name FROM ((articles a
   INNER JOIN author_article aa
   ON a.article_id = aa.article_id) INNER JOIN authors au ON aa.author_id =
   au.author_id)
   INNER JOIN users u ON au.user_id = u.user_id
   GROUP BY aa.author_id, u.name
   ORDER BY all_views DESC
   LIMIT 100
```

	all_views bigint	author_id integer	name character varying
1	1905300	83	gmendez
2	1882296	1336	dawnjackson
3	1874935	565	melindajohnson
4	1869332	1433	leonard56
5	1847895	753	ronnieharper
6	1846750	1914	lynchmary

1.2. Найти автора с самым большим количеством статей

```
SELECT count(aa.article_id), aa.author_id, u.name FROM (author_article aa INNER JOIN authors au ON aa.author_id = au.author_id)
INNER JOIN users u ON au.user_id = u.user_id
GROUP BY aa.author_id, u.name
ORDER BY count(aa.article_id) DESC
LIMIT 100
```

	count bigint	author_id integer	name character varying
1	37	1651	Imurray
2	37	179	brownjohn
3	36	330	khammond
4	35	1565	brian98
5	34	523	marydean
6	34	565	melindajohnson
7	34	1629	fcole
8	34	439	davidwhite
9	34	1075	brianmelton

1.3 Вывести пользователей, написавших больше п комментариев за последние сутки

```
SELECT c.user_id, u.name, count(c.comm_id) AS comm_count FROM comments c
INNER JOIN users u ON c.user_id = u.user_id
GROUP BY c.user_id, u.name
HAVING count(c.comm_id) > 170
ORDER BY count(c.comm_id) DESC
```

	integer	name character varying	comm_count bigint
1	8086	johnstonadam	174
2	4838	sabrinachavez	174

1.4.В каком регионе больше всего авторов

```
SELECT u.country, count(u.user_id) AS au_count FROM users u INNER JOIN authors a ON u.user_id = a.user_id
GROUP BY u.country
ORDER BY au_count DESC
```

	country character varying	au_count bigint
1	Congo	15
2	Korea	15
3	Heard Island and McDonald Islands	15
4	Morocco	14
5	Comoros	14
6	Puerto Rico	14
7	Nigeria	13
8	Cocos (Keeling) Islands	13

2.1. Вывести всех пользователей за какой-либо период, у которых х% комментариев, написанных ими, имеют рейтинг меньше у.

```
SELECT
     c.user_id,
     u.name,
     (SUM(CASE WHEN c.rating > 0 THEN 1 ELSE 0 END) * 100.0 / COUNT(*)) AS
positive_comment_percentage
FROM comments c INNER JOIN users u ON c.user_id = u.user_id
WHERE c.date > '01.01.2020'
GROUP BY c.user_id, u.name
ORDER BY c.user_id DESC
LIMIT 100
```

	user_id integer •	name character varying	positive_comment_percentage numeric
1	10000	thomasclark	54.5454545454545455
2	9999	reidalicia	63.6363636363636364
3	9998	jacob74	26.666666666666667
4	9997	breanna50	66.666666666666667
5	9996	ckennedy	53.8461538461538462
6	9995	bishopdenise	22.222222222222222
7	9994	veronicadrake	50.00000000000000000
8	9993	larsoniennifer	33.3333333333333333

2.2 Для каждого тега вывести топ авторов по максимальному рейтингу статьи за какой-то период.

```
SELECT author_id, section_id, max_rating, rankk FROM

(SELECT

aa.author_id AS author_id,

sa.section_id AS section_id,

max(a.rating) AS max_rating,

ROW_NUMBER() OVER (PARTITION BY sa.section_id ORDER BY MAX(a.rating)

DESC) AS rankk

FROM (articles a INNER JOIN author_article aa ON a.article_id =aa.article_id)

INNER JOIN article_section sa ON sa.article_id = a.article_id

GROUP BY aa.author_id, sa.section_id

ORDER BY sa.section_id, max(a.rating) DESC)

WHERE rankk <= 5
```

	author_id integer	section_id integer	max_rating integer	rankk bigint
1	1938	1	100	1
2	1758	1	100	2
3	254	1	100	3
4	1500	1	100	4
5	1916	1	100	5
6	1294	2	100	1
7	9	2	100	2
8	142	2	100	3
9	832	2	99	4

2.3. Вывести авторов, чаще всего отвечающих на комментарии под своими статьями

```
SELECT

aa.author_id,

COUNT(*) AS comment_count

FROM

(comments c INNER JOIN author_article aa ON c.article_id = aa.article_id)

INNER JOIN authors a ON a.author_id = aa.author_id

WHERE a.user_id = c.user_id

GROUP BY aa.author_id

ORDER BY comment_count DESC

LIMIT 100
```

	author_id integer	comment_count bigint
1	54	2
2	769	2
3	1198	2
4	1621	2
5	1434	2
б	1154	2
7	66	1
8	111	1
9	120	1

2.4 Для каждого тега сравнить средний рейтинг статей этого тега, со средним рейтингом по всем статьям

```
SELECT
sa.section id,
AVG(a.rating) AS avg_section_rating,
(SELECT AVG(rating) AS a FROM articles) AS avg_rating
FROM
article_section sa INNER JOIN articles a ON sa.article_id = a.article_id
GROUP BY sa.section_id
LIMIT 1000
```

	section_id integer	avg_section_rating numeric	avg_rating numeric
1	58	-0.94243070362473347548	0.30189648360331884631
2	8	2.7254901960784314	0.30189648360331884631
3	184	-2.7542372881355932	0.30189648360331884631
4	116	1.3196078431372549	0.30189648360331884631
5	87	-0.61049723756906077348	0.30189648360331884631
6	71	6.7326732673267327	0.30189648360331884631
7	68	-1.222222222222222	0.30189648360331884631
8	51	-1.1652892561983471	0.30189648360331884631
9	146	1.3155339805825243	0.30189648360331884631

3.1. Получить медианный рейтинг самой популярной статьи по авторам

max_rating integer
92

3.2 Для тега, осмотреть динамику прироста общего числа просмотров по годам/дням/месяцам

	year double precision	total_views numeric	round numeric
1	1970	546604	[null]
2	1971	1168596	53.23
3	1972	818600	-42.76
4	1973	911750	10.22
5	1974	658153	-38.53
6	1975	643612	-2.26
7	1976	835631	22.98
8	1977	981165	14.83
9	1978	414355	-136.79
10	1979	1001605	58.63

3.3. Найти самые популярные статьи для каждого тега.

Где популярная статья - это статья которая входит в тройку лучших уникальных рейтингов

```
WITH top_views AS (
SELECT
          a.article_id AS article_id,
          sa.section_id AS section_id,
          dense_rank() over(partition by sa.section_id order by a.views desc) as
rank
FROM
          articles a INNER JOIN article_section sa ON a.article_id = sa.article_id
)
SELECT top_views.article_id, top_views.section_id, top_views.rank FROM
top_views
WHERE top_views.rank <= 3
LIMIT 1000</pre>
```

	article_id integer	section_id integer	rank bigint
1	7193	1	1
2	25106	1	2
3	22275	1	3
4	15182	2	1
5	12789	2	2
6	10242	2	3
7	23749	3	1
8	6067	3	2
9	5798	3	3

3.4 Построить иерархию комментариев. Комментарий, ответы к нему, ответы к ответам и тд.

	comm_id integer	depth integer	â	path character varying (255)
1	1272898		3	1.1272893.1272897.1272898
2	1272897		2	1.1272893.1272897
3	1272893		1	1.1272893
4	1272896		1	1.1272896
5	1272894		1	1.1272894
6	1272895		1	1.1272895
7	7		0	7
8	6		0	6
9	3		0	3
10	11		0	11